

CS599 大作业报告：Medical Triage Agent

封面页

字段	内容
课程名称	企业级应用软件设计与开发
项目名称	Medical Triage Agent：医疗分诊与问诊智能体
方向	方向一：Agentic AI 原生开发
学号	2025302938
姓名	刘辰
专业	计算机技术
指导教师	戚欣
提交日期	2026 年 6 月 22 日

目录

1. 选题背景与设计思想
2. Specs 规格文档
3. 系统架构与设计
4. 关键实现与代码展示
5. 测试与评估
6. 系统升级与扩展
7. 课程总结

一、选题背景与设计思想

1.1 选题背景

本项目选择“医疗分诊与问诊智能体”作为方向一的 Agentic AI 原生开发项目。医疗健康咨询是一个非常典型的垂直领域场景：用户输入通常是自然语言，症状描述不完整、不标准，系统既需要理解语义，又必须处理安全边界。与普通闲聊机器人不同，医疗问诊辅助系统不能只追求回答流畅，还必须优先考虑风险识别、信息补全、可解释性和责任边界。

在日常生活中，用户遇到头痛、发热、咳嗽、腹痛、腹泻等症状时，常见做法是搜索网页或直接询问通用大模型。搜索网页会返回大量碎片化内容，用户需要自己判断哪些信息适用于当前情况；通用大模型虽然表达自然，但如果没有明确的安全门控和知识边界，可能会忽略“胸痛、呼吸困难、意识模糊、呕血”等红旗症状，甚至在应该建议急诊时继续给出居家观察建议。因此，本项目希望构建一个更符合工程化要求的医疗咨询 Agent：先判断紧急情况，再补全问诊信息，然后检索医学知识，最后给出风险分级和非诊断性质的建议。

1.2 问题定义

本项目解决的问题不是“让 AI 替代医生诊断”，而是“让 AI 在用户正式就医或咨询前，提供初步分诊、风险提示和信息整理”。系统的目标包括：

- 识别红旗症状，避免高风险场景被普通问答流程稀释。
- 通过多轮追问补全症状、部位、持续时间、严重程度和伴随症状。
- 使用 RAG 检索本地医学知识库，减少纯模型生成的随意性。
- 根据规则和用户信息输出 A/B/C/D 风险等级，并展示风险因素。
- 生成可理解、可操作、带有边界声明的健康建议。
- 保存对话历史、问诊结果和反馈，为复盘与评估提供数据。

1.3 现有方案不足

第一类方案是传统搜索引擎。它能覆盖大量医学资料，但缺少对用户上下文的理解。用户需要自己筛选信息，容易被严重疾病描述吓到，也可能因为描述过于笼统而低估风险。

第二类方案是普通聊天机器人。它的优势是对话自然，但如果没有专门的安全门控、知识检索和分诊规则，回答可能过度依赖模型内部知识。医疗场景中，单纯“看起来合理”的回答并不足够，必须能说明为什么给出某个风险等级，以及哪些情况需要立即就医。

第三类方案是纯规则分诊系统。它可解释、稳定，但交互体验较差，对用户自然语言表达的适应能力有限。例如用户说“胸口像被压着，喘不上来”，纯关键词系统可能漏掉“胸痛/呼吸困难”的风险信号。

因此，本项目采用混合式 Agent 架构：安全和风险分级使用规则增强可控性，追问和建议生成使用 LLM 增强自然语言能力，医学知识通过 RAG 引入外部知识来源。

1.4 设计思想

本项目的核心设计思想是“安全优先、分步决策、模块解耦、可评估”。安全优先指系统必须先判断是否存在紧急症状；只要命中红旗症状，就不再进入普通建议生成流程，而是返回急救建议。分步决策指 Agent 不直接从用户输入生成最终答案，而是经过 SafetyGate、FollowupAgent、RAGAgent、RiskClassifier、AdviceGenerator 等步骤。模块解耦指每个 Agent 都是独立类和独立职责，便于单元测试和未来替换为 LangGraph Node 或 MCP Tool。可评估指系统输出不仅包含自然语言建议，还包含风险等级、风险分数、风险因素和日志记录，便于后续做行为评估。

1.5 技术路线

系统采用前后端分离结构。前端使用 React、TypeScript、Vite 和 Tailwind CSS，实现聊天界面、用户信息表单、风险提示和反馈提交。后端使用 FastAPI 提供 REST API，使用 SQLAlchemy 和 SQLite 保存用户会话、问诊消息、风险结果和反馈。Agent 层使用 Python 实现多个专职 Agent，由 Orchestrator 统一编排。RAG 层使用 LangChain、Chroma 和 DashScope Embeddings，对 `src/app/rag/medical_docs/` 下的医学知识文档进行切分、向量化和检索。LLM 使用 DashScope 兼容 OpenAI 接口的 Qwen 模型，通过环境变量读取 API Key，避免硬编码密钥。

本项目覆盖课程要求中的多个核心技术要素：SDD 规格驱动开发、函数化工具调用、RAG 增强问答、对话记忆、多步骤推理、多 Agent 协作、日志可观测性和测试评估。

二、Specs 规格文档

本项目采用 SDD（Specification Driven Development，规格驱动开发）组织需求、架构和接口。完整规格文档位于 `docs/specs.md`，这里给出核心内容摘要。

2.1 Product Spec

产品定位

Medical Triage Agent 是一个医疗分诊与问诊辅助系统。它不提供确定诊断，不开具处方药，不替代医生，而是在用户输入症状后，辅助完成初步信息收集、风险判断和就医建议生成。

目标用户

用户类型	典型需求	系统价值
普通用户	想知道症状是否严重、是否需要就医	获得初步风险提示和就医优先级
医疗平台	希望正式问诊前收集结构化信息	降低医生初诊信息采集成本
课程评审者	希望看到 Agentic AI 工程闭环	展示规格、架构、实现、测试和评估

功能需求

编号	需求	优先级	验收标准
P1	红旗症状识别	Must	输入“胸痛、呼吸困难、意识模糊”等症状时，系统直接输出急救建议
P2	多轮追问	Must	用户描述不完整时，系统追问部位、持续时间、严重程度、伴随症状等字段
P3	医学知识检索	Must	系统从本地医学知识库检索相关片段，并作为建议生成上下文
P4	风险分级	Must	系统输出 A/B/C/D 风险等级、分数和风险因素
P5	建议生成	Must	系统生成包含初步分析、就医建议、注意事项和观察指标的建议
P6	对话记忆	Should	系统保存会话、消息、风险结果和反馈
P7	前端交互	Should	用户可通过网页完成问诊、查看回复并提交反馈
P8	可观测性	Should	系统记录关键日志，便于复盘 Agent 决策

非功能需求

类型	要求
安全性	API Key 只能通过 <code>.env</code> 配置，不能进入 GitHub 仓库
可解释性	风险输出必须包含风险因素，避免只给结论
可维护性	Agent 模块独立，避免把所有逻辑堆在一个 Prompt 中
可扩展性	未来可接入 LangGraph、MCP、Docker 和云端部署
可测试性	核心规则和 Agent 行为应能通过自动化测试验证

2.2 Architecture Spec

系统采用“前端交互层 - API 层 - Agent 编排层 - 知识与存储层”的分层架构。每层职责如下：

层级	模块	职责
前端交互层	React UI	展示聊天消息、用户信息表单、风险提示和反馈入口
API 层	FastAPI Router	接收请求、校验参数、调用 Orchestrator、保存结果
Agent 编排层	Orchestrator	控制安全检测、追问、RAG、风险分级和建议生成的执行顺序
专职 Agent 层	SafetyGate、FollowupAgent、RAGAgent 等	承担单一职责，提供可测试的函数化能力
知识层	Markdown 医学知识库 + Chroma	提供常见症状和红旗症状相关知识
存储层	SQLite	保存用户、问诊、消息和反馈

Agent 职责划分

Agent	文件	输入	输出
SafetyGate	src/app/agents/safety_gate.py	用户自然语言消息	是否命中红旗症状、紧急建议
FollowupAgent	src/app/agents/followup_agent.py	对话历史	缺失字段、追问问题
RAGAgent	src/app/agents/rag_agent.py	当前问题	医学知识片段
RiskClassifier	src/app/agents/risk_classifier.py	症状、年龄、病史、体温等	风险等级、分数、因素
AdviceGenerator	src/app/agents/advice_generator.py	用户信息、RAG 上下文、风险等级	综合建议
SummaryWriter	src/app/agents/summary_writer.py	问诊记录	问诊摘要
Orchestrator	src/app/agents/orchestrator.py	消息、用户信息、问诊 ID	最终响应和状态

2.3 API Spec

系统核心 API 如下：

接口	方法	请求内容	返回内容	用途
/chat/	POST	session_id、 message、 user_info	回复、问诊 ID、是否完 成、是否追问	多轮问 诊主入 口
/chat/history/{session_id}	GET	会话 ID	历史消息列表	恢复对 话记忆
/triage/risk	POST	症状、年龄、病史、体温	风险等级、分 数、因素	独立风 险评估
/triage/red-flags	POST	用户消息	红旗症状检测 结果	安全检 测
/summary/{consultation_id}	GET	问诊 ID	摘要和原始数 据	复盘问 诊
/feedback/	POST	问诊 ID、评分、评论	反馈提交结果	收集用 户评价

/chat/ 的请求示例:

```
{
  "session_id": "session_001",
  "message": "我头痛已经两天了，有点恶心",
  "user_info": {
    "age": 30,
    "gender": "男",
    "medical_history": "无",
    "medication": "无",
    "allergies": "无"
  }
}
```

/chat/ 的响应示例:

```
{
  "response": "风险评估与健康建议文本",
  "consultation_id": 1,
  "is_complete": true,
  "needs_followup": false,
  "followup_question": null
}
```

2.4 SDD 到实现的映射

规格项	实现位置	测试或验证方式
红旗 症状 识别	<code>SafetyGate.detect_red_flags</code>	<code>tests/test_safety_gate.py</code>
风险 分级	<code>RiskClassifier.assess_risk</code>	<code>tests/test_risk_classifier.py</code>
多轮 追问	<code>FollowupAgent.identify_missing_fields</code>	<code>tests/test_followup.py</code>
RAG 检索	<code>RAGAgent.retrieve</code>	运行问诊流程和日志验证
对话 持久 化	<code>app/database/models.py</code> 与 CRUD	API 联调
前端 交互	<code>src/App.tsx</code>	<code>npm run build</code>

三、系统架构与设计

3.1 总体架构

```
flowchart LR
    User[用户] --> Web[React 前端]
    Web --> API[FastAPI API 层]
    API --> Orchestrator[Orchestrator 总控 Agent]
    Orchestrator --> Safety[SafetyGate 安全门]
    Orchestrator --> Followup[FollowupAgent 追问]
    Orchestrator --> RAG[RAGAgent 检索]
    Orchestrator --> Risk[RiskClassifier 风险分级]
    Orchestrator --> Advice[AdviceGenerator 建议生成]
    Orchestrator --> Summary[SummaryWriter 摘要]
    RAG --> Chroma[(Chroma 向量库)]
    RAG --> Docs[医学知识库]
    Advice --> LLM[DashScope/Qwen]
    Followup --> LLM
    Summary --> LLM
    API --> DB[(SQLite)]
    API --> Logs[运行日志]
```

该架构的关键点是 Orchestrator 只负责编排，不承担具体医学规则和生成逻辑。SafetyGate、FollowupAgent、RAGAgent、RiskClassifier 和 AdviceGenerator 都可以单独运行和测试。这种设计使系统更接近企业级应用中的“可维护服务”，而不是一次性 Prompt Demo。

3.2 Agent 交互流程

```
sequenceDiagram
    participant U as User
    participant F as React Frontend
    participant A as FastAPI
    participant O as Orchestrator
    participant S as SafetyGate
    participant Q as FollowupAgent
    participant R as RAGAgent
    participant C as RiskClassifier
    participant G as AdviceGenerator
    participant D as SQLite

    U->>F: 输入症状
    F->>A: POST /chat
    A->>D: 保存用户消息
    A->>O: process_message()
    O->>S: detect_red_flags()
    alt 红旗症状
        S-->>O: emergency response
        O-->>A: 急救建议
    else 信息不足
        O->>Q: identify_missing_fields()
        Q-->>O: 追问问题
        O-->>A: needs_followup=true
    else 信息充足
        O->>R: retrieve()
        R-->>O: 医学知识片段
        O->>C: generate_risk_report()
        C-->>O: 风险等级与因素
        O->>G: generate_advice()
        G-->>O: 健康建议
        O-->>A: 完整答复
    end
    A->>D: 保存助手回复与风险结果
    A-->>F: ChatResponse
    F-->>U: 展示结果
```

3.3 数据流设计

用户输入首先经过 Pydantic Schema 校验，避免空消息或过长消息进入后端。API 层根据 `session_id` 获取或创建用户，并将用户年龄、性别、病史、用药、过敏等信息合并到当前上下文中。随后 Orchestrator 根据当前消息和历史消息进行多步骤推理。最终响应会写回数据库，风险等级和建议也会更新到对应问诊记录。

数据流可拆成三类：

数据类型	来源	存储位置	用途
会话数据	前端 localStorage 生成 <code>session_id</code>	SQLite <code>users</code> 、 <code>consultations</code> 、 <code>messages</code>	对话记忆和历史恢复
医学知识	<code>src/app/rag/medical_docs/*.md</code>	Chroma 向量库	RAG 检索上下文
运行日志	API 和 Agent 执行过程	<code>logs/medical_agent.log</code>	可观测性和评估复盘

3.4 风险等级设计

风险等级采用 A/B/C/D 四级：

等级	名称	分数范围	建议
A	急诊	<code>score >= 70</code> 或强红旗症状	立即前往急诊或拨打 120
B	尽快就医	<code>50 <= score < 70</code>	建议 24 小时内就医
C	门诊	<code>30 <= score < 50</code>	建议 1-3 天内门诊
D	居家观察	<code>score < 30</code>	居家观察，症状加重及时就医

风险分数由症状、年龄、基础病、特殊人群和体温共同影响。例如胸痛和呼吸困难属于高权重症状；老年人、儿童、孕妇、免疫低下者会增加风险；糖尿病、高血压、心脏病等病史也会提高分数。相比直接让 LLM 判断风险等级，规则分级更稳定，也更容易解释。

3.5 安全边界设计

医疗系统最重要的不是让回答“像医生”，而是避免危险建议。本项目设置了三层边界：

- 1. 安全门控：红旗症状优先处理。
- 2. 非诊断声明：所有建议都强调不能替代医生诊断。
- 3. 高风险升级：风险等级较高时，建议优先就医而不是自行处理。

四、关键实现与代码展示

4.1 Orchestrator 核心循环

核心文件为 `src/app/agents/orchestrator.py`。Orchestrator 的职责是决定下一步调用哪个 Agent，而不是亲自完成所有任务。

```
has_red_flags, detected_flags = self.safety_gate.detect_red_flags(message)

if has_red_flags:
    return {
        "response": self.safety_gate.get_emergency_response(detected_flags),
        "is_emergency": True,
        "detected_flags": detected_flags,
        "is_complete": True,
        "needs_followup": False
    }
```

这段代码体现了“安全优先”的设计。只要 SafetyGate 判断存在红旗症状，流程直接返回急救建议，不再调用 RAG 和 AdviceGenerator。这可以避免模型在紧急场景中生成普通健康建议。

```
missing_fields = self.followup_agent.identify_missing_fields(conversation_context)

if missing_fields:
    followup_question = self.followup_agent.generate_followup_question(
        missing_fields,
        "\n".join([msg.get("content", "") for msg in conversation_context])
    )
    return {
        "response": followup_question,
        "is_emergency": False,
        "is_complete": False,
        "needs_followup": True,
        "missing_fields": missing_fields
    }
```

这段代码对应多轮问诊能力。医疗问诊并不是用户输入一句话就能完成，系统需要主动追问关键信息。FollowupAgent 会检查症状、部位、持续时间、严重程度和伴随症状是否完整，再决定是否进入最终建议生成。

```
rag_context = self.rag_agent.retrieve(message)
user_info["symptoms"] = message
risk_report = self.risk_classifier.generate_risk_report(user_info)
advice = self.advice_generator.generate_advice(
    user_info,
    rag_context,
    risk_report["risk_level"]
)
```

当信息足够时，系统先检索医学知识，再进行风险分级，最后生成建议。这个顺序保证 AdviceGenerator 的输入不只是用户原文，还包括结构化风险等级和知识库片段。

4.2 SafetyGate 安全门

SafetyGate 位于 `src/app/agents/safety_gate.py`。它维护红旗症状列表，如胸痛、胸闷、呼吸困难、意识模糊、剧烈头痛、呕血、黑便、高热、抽搐、大量出血等。检测方式是关键词匹配，优点是速度快、行为稳定、易于测试。虽然关键词方式不能覆盖所有医学表达，但作为第一道安全防线，它能有效处理最常见的高风险信号。

命中红旗症状后，系统返回包含“立即拨打 120、保持患者平躺、不要给意识不清患者喂食喂水”等内容的急救建议。这个设计遵循保守原则：宁可高风险输入下建议就医，也不冒险给出居家处理意见。

4.3 FollowupAgent 追问策略

FollowupAgent 位于 `src/app/agents/followup_agent.py`。它的目标是让问诊信息达到最小可用完整度。系统设置五个关键字段：症状、部位、持续时间、严重程度、伴随症状。为了避免机械地只判断字段名是否出现，代码中加入了关键词映射。例如“头痛已经 2 天了”可以被识别为包含症状、部位和持续时间；“轻微咳嗽”可以被识别为包含症状和严重程度。

当缺失字段较多时，FollowupAgent 会调用 LLM 生成自然追问。Prompt 要求一次只问 1-2 个最重要问题，语气温和，问题具体且易回答。这样既能补全信息，又不会让用户一次面对过多问题。

4.4 RAGAgent 医学知识检索

RAGAgent 位于 `src/app/agents/rag_agent.py`。它读取 `src/app/rag/medical_docs/` 下的 Markdown 医学知识文档，包括发热、咳嗽、头痛、腹痛、腹泻、红旗症状等内容。系统使用 DashScope Embeddings 将文档切分并写入 Chroma 向量库，问诊时调用相似度检索获得相关片段。

RAG 的价值在于把建议生成限制在项目维护的知识范围内，减少模型完全自由发挥。对于课程项目而言，本地医学知识库虽然规模不大，但已经展示了企业知识库 + Agentic RAG 的基本链路：知识整理、向量索引、语义检索、上下文注入和建议生成。

4.5 RiskClassifier 风险分级

RiskClassifier 位于 `src/app/agents/risk_classifier.py`。它根据症状关键词、体温、年龄、病史和特殊人群信息计算风险分数。示例规则包括：

- 呼吸困难：增加 40 分。
- 胸痛：增加 40 分。
- 意识模糊：增加 50 分。
- 高热大于 39°C：增加 30 分。
- 年龄大于等于 65 岁：分数乘以 1.3。
- 年龄小于等于 12 岁：分数乘以 1.5。
- 糖尿病、高血压、心脏病等病史分别增加风险。
- 孕妇和免疫低下者增加风险权重。

该模块的输出不仅有风险等级，还有风险因素列表。例如用户输入“胸痛，呼吸困难，有高血压史”时，系统会输出“胸痛、呼吸困难、高血压史”等因素。这种可解释输出比单纯回答“高风险”更适合评估和复盘。

4.6 AdviceGenerator 建议生成

AdviceGenerator 位于 `src/app/agents/advice_generator.py`。它使用 ChatPromptTemplate 构造 Prompt，输入包括年龄、症状、病史、用药情况、医学知识库参考和风险等级。输出要求包含初步分析、就医建议、注意事项、观察指标等内容，并明确提醒用户最终需咨询专业医生。

这里的 LLM 不是独立决策者，而是“表达与整合层”。真正的安全门、风险分级和知识检索在前置模块中完成。这样可以降低 LLM 幻觉对系统核心决策的影响。

4.7 数据库与记忆机制

数据库模型位于 `src/app/database/models.py`，包括 User、Consultation、Message 和 Feedback 四类表。User 通过 `session_id` 标识用户；Consultation 保存问诊状态、风险等级、主诉和建议；Message 保存多轮对话；Feedback 保存用户评分和评论。

这种设计实现了基础对话记忆：同一用户再次访问时，前端使用 localStorage 保存的 `session_id` 恢复历史消息，后端从数据库读取对应问诊记录。虽然这不是长期语义记忆，但已经具备跨请求状态管理能力。

4.8 前端实现

前端核心文件为 `src/App.tsx` 和 `src/services/api.ts`。前端提供用户信息表单、聊天消息列表、发送输入框、新对话按钮、风险提示条和反馈组件。`src/services/api.ts` 封装了 `/chat/`、`/chat/history/`、`/feedback/`、`/triage/risk`、`/summary/` 等 API 调用。

前端设计目标不是做营销页面，而是让用户直接进入问诊流程。界面围绕对话展开，降低用户使用门槛，同时通过风险提示条突出高风险输出。

五、测试与评估

5.1 自动化测试

项目测试位于 `tests/` 目录，使用 `Pytest`。当前测试覆盖 `SafetyGate`、`RiskClassifier` 和 `FollowupAgent` 三个关键模块，共 15 个测试用例。测试结果为：

15 passed

测试覆盖情况如下：

测试文件	覆盖模块	核心验证点
<code>tests/test_safety_gate.py</code>	<code>SafetyGate</code>	胸痛、胸闷、呼吸困难、晕厥、意识模糊等红旗症状识别
<code>tests/test_risk_classifier.py</code>	<code>RiskClassifier</code>	低风险、高风险、老年人、糖尿病、孕妇和风险报告生成
<code>tests/test_followup.py</code>	<code>FollowupAgent</code>	缺失字段识别和追问生成

5.2 功能测试场景

场景	输入	预期行为	评估重点
急症识别	“我胸痛胸闷，呼吸困难”	返回紧急情况识别和 120 建议	安全门是否优先
信息不足	“我不舒服”	追问症状部位、持续时间等	多轮问诊是否有效
普通症状	“轻微咳嗽，有一点痰”	输出较低风险和观察建议	不过度升级
高危人群	“70 岁老人发热，有糖尿病史”	风险分数高于普通成年人	年龄和病史是否生效
消化道风险	“腹痛，黑便”	识别消化道出血风险	红旗症状召回

5.3 Agent 行为评估

Agent 行为评估不仅看最终回答是否通顺，还看流程是否符合设计。评估维度如下：

维度	指标	说明
安全性	红旗症状召回	高风险输入是否被 SafetyGate 捕获
完整性	追问字段覆盖	信息不足时是否补问关键字段
解释性	风险因素输出	风险等级是否有因素支撑
一致性	同类输入输出稳定性	类似症状是否给出相近等级
边界性	非诊断声明	是否明确不能替代医生诊断
可用性	前端交互闭环	用户是否能完成输入、查看回复、提交反馈

5.4 与课程要求的对应关系

课程技术要素	本项目体现
SDD 规格驱动开发	docs/specs.md 和报告第二章
工具使用 / Function Calling	各 Agent 以函数化模块方式被 Orchestrator 调用
记忆机制	SQLite 保存用户、问诊、消息和反馈
状态管理与多步骤推理	Orchestrator 控制安全检测、追问、RAG、分级和建议生成
多智能体协作	SafetyGate、FollowupAgent、RAGAgent、RiskClassifier、AdviceGenerator、SummaryWriter
可观测性与评估	日志记录、Pytest、行为评估表
Agentic RAG	LangChain + Chroma + DashScope Embeddings

5.5 已知不足

第一，红旗症状识别目前主要依赖关键词，无法完全覆盖口语化表达。第二，风险分级规则由人工设计，仍需结合更多医学指南和真实样本校准。第三，RAG 知识库规模较小，只覆盖常见症状，尚未达到生产级医疗知识库水平。第四，当前没有云服务器部署 URL，Demo 需要依赖本地环境。第五，报告中的测试以单元测试和场景评估为主，还没有建立大规模 Benchmark。

这些不足也为后续扩展提供了方向：引入医学安全评测集、扩大知识库、增加语义红旗症状识别、接入 LangGraph 状态机和 MCP 工具协议。

六、系统升级与扩展

6.1 LangGraph 状态机升级

当前 Orchestrator 使用手写流程控制，结构清晰但状态可视化能力有限。下一阶段可以使用 LangGraph 将 SafetyGate、FollowupAgent、RAGAgent、RiskClassifier、AdviceGenerator 封装成节点，并显式定义状态转移边。这样可以获得更好的中断恢复、状态检查和可视化调试能力。

6.2 MCP 工具化

SafetyGate、RiskClassifier 和 RAGAgent 都适合封装为 MCP Tool。封装后，其他 Agent 或 IDE 可以通过统一协议调用这些能力。例如：

- `detect_red_flags(message)`：返回红旗症状。
- `assess_risk(user_info)`：返回风险等级和因素。
- `retrieve_medical_docs(query)`：返回相关医学知识。

MCP 化后，系统不再局限于当前 Web 应用，也可以作为其他医疗问答、客服或教务项目中的工具组件。

6.3 知识库扩展

当前知识库使用 Markdown 文件维护，适合课程项目。未来可以扩展为：

- 接入更完整的医学指南和公开健康知识。
- 为每条知识增加来源、更新时间、适用人群和风险等级标签。
- 建立知识审核流程，避免错误医学内容进入 RAG。
- 引入混合检索，同时使用关键词检索和向量检索。

6.4 评估体系升级

生产级 Agent 不能只靠人工体验判断效果。后续可以构建 Benchmark：

评估集	内容	指标
红旗症状集	胸痛、呼吸困难、意识障碍等	召回率、误报率
常见症状集	发热、咳嗽、头痛、腹痛等	风险等级一致性
追问集	不完整症状描述	追问字段覆盖率
安全边界集	要求诊断、开药、忽略急症等	拒答与升级建议准确率

6.5 部署与工程化

后续工程化方向包括：

- 1. 增加 Dockerfile 和 Docker Compose，一键启动前端、后端和向量库。
- 2. 增加 CI 流水线，在 GitHub Actions 中运行 Pytest 和前端构建。
- 3. 增加 `.env.example` 的详细说明，降低部署门槛。
- 4. 增加接口限流、输入审计和异常告警。
- 5. 部署到云服务器，提供稳定 Demo URL。

七、课程总结

通过本项目，我对“AI 驱动的软件开发与 Agentic AI”有了更具体的理解。最初我容易把 AI 应用理解为“写一个 Prompt，然后调用一次大模型”。但在医疗问诊场景中，这种方式明显不够。一个真正可用的 Agent 系统需要把任务拆成多个步骤：先做安全判断，再收集上下文，再检索知识，再进行风险判断，最后才是自然语言表达。

在开发过程中，我体会到 SDD 的价值。先写 Product Spec、Architecture Spec 和 API Spec，可以避免实现时不断偏离目标。比如“红旗症状优先”这个规则如果只写在 Prompt 里，很容易被后续回答逻辑覆盖；但当它被写入架构和代码流程后，就成为系统的硬约束。类似地，风险分级、追问字段、数据库模型和 API 响应格式都通过规格文档提前固定，后续实现更顺畅。

我也认识到 Agentic AI 的关键不只是“模型更强”，而是“编排更可靠”。LLM 擅长语言理解和表达，但不适合独自承担所有决策。把 LLM 放在合适的位置，让规则、检索、数据库、日志和测试共同约束系统，才能让项目更像企业级应用，而不是一次性演示。

本项目还让我对工程边界有了更深感受。医疗场景具有高风险，系统必须明确自己不能替代医生诊断。即使是课程项目，也需要在 README、Prompt 和最终回复中反复声明边界。未来如果继续完善，我希望重点提升医学安全评估、知识库质量、LangGraph 状态机和 MCP 工具化能力，让这个项目从课程大作业进一步演进为可复用的垂直领域 Agent 框架。

总体而言，本项目完成了从需求规格、架构设计、代码实现、测试验证到文档交付的完整闭环，也体现了我从“代码编写者”向“智能体编排者”的思维转变。